

Ground truth de evaluacion para el sistema RAG

Como se construyo **ground_truth.json**: insumos reales, origen de los identificadores, metodologia de seleccion, validaciones y limites conocidos.

Concepto	Valor
Preguntas procesadas	50
Fragmentos referenciados	250 (5 por pregunta)
Chunks distintos citados	234
Preguntas con menos de 5 fuentes	0
Preguntas con salvedades en notes	14
source_file nulos	0
Corpus indexado	128.476 chunks / 1.826 documentos

1. Los insumos no eran los descritos

Antes de cualquier decision metodologica conviene dejar por escrito que dos de los tres insumos previstos no existian con esa forma en el repositorio.

Lo previsto	Lo que hay realmente
chunking/fragmentos.json	Chunking/fragmentos.rar (27 MB). Al descomprimir: fragmentos.jsonl (337 MB, formato JSON Lines, un objeto por linea) y reporte_fragmentacion.json.
Carpeta preguntas/ con las preguntas	Preguntas/Extracto_Preguntas_50_v2.pdf: un unico PDF de 3 paginas con las 50 preguntas ya numeradas q001 a q050.
Posible ausencia de archivo de origen	No aplica. Cada chunk trae el campo fuente con el nombre del documento original, asi que ningun source_file quedo en null.

2. De donde salen los chunk_id

No se creo ni se invento ningun identificador. El campo chunk_id ya viene en cada linea del JSONL. Se copia tal cual al ground truth; el generador no lo construye, solo lo lee.

Linea cruda del corpus, sin modificar:

```
{"chunk_id": "F1-CSET-110-c0029", "doc_id": "F1-CSET-110", "fenomeno": 1, "formato": "pdf", "fuente": "CSET_center-for-security-and-emerging-technology-6.pdf", "idioma": "en", "n_oraciones": 11, "num_palabras": 213, ...}
```

Quien lo genera es el propio pipeline del proyecto, no este trabajo. En fragmentador.py esta la funcion que lo compone y la validacion que lo verifica:

```
def chunk_id_de(doc_id: str, posicion: int) -> str:
    """Identificador del fragmento. Cuatro digitos ordenan bien hasta 9999."""
    return f"{doc_id}-c{posicion:04d}"
```

De ahi que un identificador como F1-CSET-110-c0029 se lea asi:

Parte	Significado
-------	-------------

F1	Fenomeno 1 (IA y capacidades estrategicas). F2 = seguridad del entorno espacial, F3 = dinamicas territoriales.
CSET	Observatorio o fuente institucional (CSET Georgetown).
110	Numero de documento dentro de ese observatorio.
c0029	Posicion del fragmento dentro del documento, con cuatro digitos para que ordene bien.

La consecuencia practica es que todo chunk_id del ground truth resuelve contra el corpus. Se comprobo releendo el JSONL completo desde cero, sin usar el indice intermedio: los 234 identificadores distintos aparecen en el archivo original.

3. Metodologia

El corpus tiene 128.476 chunks: leerlos todos no es posible. La estrategia fue reducir cada pregunta a un conjunto pequeno de candidatos por recuperacion automatica y decidir la relevancia a mano sobre ese conjunto.

3.1 Indice BM25 sobre el corpus completo

Se construyo un indice disperso (matriz CSR de 128.476 x 261.126 terminos, 9,2 millones de posiciones no nulas) sobre el texto de cada chunk mas su seccion, fuente y observatorio. Se guarda ademas el desplazamiento en bytes de cada linea, de modo que el texto se recupera con una lectura puntual y nunca se cargan los 337 MB en memoria.

3.2 Expansion bilingue de consultas

Es la decision que mas peso tuvo en la calidad. El corpus es 75% ingles, 18% espanol y 7% portugues, mientras que las 50 preguntas estan en espanol. Una busqueda literal en espanol deja fuera la mayor parte del material. Por eso cada pregunta lleva escrito a mano un conjunto de terminos equivalentes en ingles y, donde aplica, en portugues. Ejemplo para q001, sobre amenazas NBQR:

```
"CBRN chemical biological radiological nuclear threats detection artificial intelligence  
biosecurity bioweapons nonproliferation dual-use pathogen screening NBQR quimico biologico  
radiologico"
```

3.3 Filtrado de ruido

Ciertos fragmentos puntuan alto en BM25 precisamente porque repiten terminos clave, pero no sustentan ninguna respuesta. Se descartan automaticamente:

- indices y tablas de contenido, detectados por una razon de palabras por oracion superior a 55;
- bibliografias, por acumulacion de URLs, llamados de referencia entre corchetes o densidad alta de anios;
- filas de CSV y JSON tabular, por abundancia de separadores;
- listas de terminos separadas por comas, por densidad de comas;
- fragmentos de menos de 45 palabras y teselas vectoriales .pbf.

Se anade una deteccion de texto de relleno editorial: si un mismo contenido reaparece con similitud de Jaccard mayor a 0,5 en tres o mas documentos distintos, se descarta el grupo entero. Esto elimino, por ejemplo, el catalogo de publicaciones que el observatorio DAIO repite al final de cada estudio y que acaparaba los primeros puestos de varias preguntas.

3.4 Revision manual y consultas dirigidas

Para cada pregunta se genero un pool de once candidatos: ocho restringidos al fenomeno correspondiente y tres sin restriccion, para no perder material relevante alojado en otro fenomeno. Los tres pools completos se leyeron y se decidio la relevancia y el orden a mano. Las preguntas cuyo pool quedo debil recibieron rondas adicionales de consultas dirigidas con vocabulario mas especifico; fueron q004, q006, q010, q011, q012, q027, q028, q030, q032, q035, q037, q042, q043, q046, q047 y q050.

3.5 Extraccion de los excerpt

Los excerpt no se redactan: se extraen. Para cada seleccion se registra un ancla, un texto que debe aparecer literalmente en el chunk, y el generador toma desde ahi una ventana de unos 300 caracteres cortada en frontera de palabra. Si el chunk_id no existe o el ancla no aparece, el script **falla en lugar de producir una salida aproximada**. Ese control detecto ocho anclas mal transcritas durante la construccion,

que se corrigieron.

Unica transformacion aplicada: normalizacion de espacios en blanco. Los PDF del corpus vienen con saltos de linea y columnas entrelazadas, de modo que el texto crudo es ilegible sin ese ajuste. No se altera, sustituye ni reordena ninguna palabra.

4. Formato de salida

```
[
  {
    "question_id": "q001",
    "question": "¿Cómo está transformando la inteligencia artificial ...?",
    "relevant_chunks": [
      {
        "rank": 1,
        "chunk_id": "F1-CSET-110-c0029",
        "source_file": "CSET_center-for-security-and-emerging-technology-6.pdf",
        "excerpt": "Protect against AI-enabled biological risks There are concerns ..."
      }
    ],
    "notes": "opcional, solo cuando aplica"
  }
]
```

rank va de 1 a 5 en orden decreciente de relevancia. source_file reproduce el campo fuente del chunk. notes aparece solo en las 14 preguntas con salvedades.

5. Resultados

Distribucion de los 250 fragmentos por fenomeno y por observatorio de origen:

Fenomeno		Fragmentos	
F1 - IA y capacidades estrategicas		69	
F2 - Seguridad del entorno espacial		73	
F3 - Dinamicas territoriales		108	

Observatorio	Frag.	Observatorio	Frag.
MAPPOEA	59	ILIA	9
SWF	43	CEEEP	6
DAIO	31	UNOOSA	4
CSET	26	AIINDEX	3
ALERTAS	25	ESA	2
CSIS	24	RESDAL	2
SIPRI	16		

6. Validaciones ejecutadas

Sobre el archivo final, releendo el JSONL original desde cero:

- los 234 chunk_id distintos existen en el corpus;
- los 250 excerpt son subcadena literal del texto del chunk que citan;
- cada source_file coincide con el campo fuente del chunk;
- los rank son consecutivos desde 1 en las 50 preguntas;

- ningun source_file es null y ningun excerpt esta vacio;
- los 50 question_id son unicos y corresponden a los del PDF de preguntas.

Resultado: **0 fallos**.

7. Salvedades registradas

Las 50 preguntas alcanzaron cinco fragmentos, pero cinco fragmentos recuperables no equivalen a cinco fragmentos que respondan con la misma solidez. Donde la evidencia es parcial o indirecta, queda anotado en el campo notes de la pregunta. Afecta a 14 preguntas:

ID	Salvedad
q001	El corpus trata el vinculo IA-NBQR sobre todo desde el riesgo de que los modelos faciliten el desarrollo de armas QBRN y desde las salvaguardas para evitarlo; no hay fragmentos sobre sistemas de IA usados por los Estados para deteccion y respuesta NBQR en campo.
q004	Ninguna fuente cuantifica el riesgo de la escasez de talento para capacidades de defensa; los fragmentos documentan la brecha de talento y sus efectos sobre la adopcion de IA de defensa en paises concretos (Israel, Dinamarca, Brasil, Corea del Sur) y en America Latina.
q005	No hay fragmentos sobre dependencia de IA extranjera referidos especificamente a Colombia; los seleccionados tratan la soberania tecnologica de forma general y para America Latina.
q010	Solo F1-DAIO-033-c0057 describe una capacidad antidron explicitamente basada en IA (sistema Merops). Los demas aportan contexto de contra-UAS, identificacion de amenazas y neutralizacion por guerra electronica sin componente de IA declarado.
q012	El corpus no documenta la conversion de experiencia operacional militar en datos de entrenamiento. Los fragmentos cubren lo mas cercano disponible: gobernanza de datos de defensa, plataformas para compartir datos y construccion y etiquetado de conjuntos de datos.
q014	Los fragmentos miden la capacidad de computo a escala nacional y regional, no para defensa; el corpus no vincula de forma explicita la falta de computo con capacidades militares de IA.
q027	Los fragmentos mas pertinentes provienen de material de IA (CSET) y no del acervo espacial; el corpus espacial aborda la autonomia a bordo y la IA responsable en observacion de la Tierra, pero no los desafios de la IA en operaciones espaciales militares.
q030	El corpus no usa la expresion dynamic space operations. Los fragmentos recogen la evolucion doctrinal estadounidense equivalente: superioridad espacial, competitive endurance, guerra orbital y el marco de prioridades espaciales.
q031	La evidencia contradice la premisa de la pregunta: las fuentes coinciden en que Corea del Norte no tiene una doctrina espacial o contraespacial declarada. Los fragmentos documentan esa ausencia y los avances materiales (satelite Malligyong-1, reorganizacion de la agencia espacial) que si se regis...
q037	El corpus aborda la influencia del crimen organizado sobre el Estado de forma indirecta y dispersa (cooptacion de funcionarios, despojo con anuencia de notarias, debilitamiento de la gobernabilidad); no hay fragmentos dedicados a describir el mecanismo.
q046	El unico mineral que el corpus documenta como fuente de financiacion es el oro. No se encontraron fragmentos sobre coltan, casiterita u otros minerales estrategicos.
q047	No hay fragmentos sobre disputa por rutas aereas. Los seleccionados documentan corredores maritimos, fluviales y terrestres para narcotrafico, armas y contrabando, y un unico registro de destruccion de pistas clandestinas de aterrizaje (Guatemala).
q049	El corpus documenta el proceso de restitution de tierras y el riesgo sobre los reclamantes, pero no describe de forma directa como el accionar de los grupos armados obstaculiza el tramite; los fragmentos aportan la evidencia parcial disponible.
q050	El corpus es mayoritariamente colombiano; los fragmentos cubren la adaptacion criminal via alianzas, reacomodos y expansion transfronteriza, pero no las transformaciones ambientales ni tecnologicas que menciona la pregunta.

7.1 Preguntas cuyo supuesto no coincide con el corpus

Tres preguntas dan por sentado un contenido que la base de conocimiento no tiene. En estos casos se selecciono lo mas cercano que realmente existe y se dejo constancia, en lugar de forzar coincidencias que inflarian artificialmente la evaluacion.

Pregunta	Discrepancia
q031	Pregunta que cambios doctrinales fortalecieron las capacidades espaciales de Corea del Norte. Las fuentes afirman lo contrario: que no existe doctrina contraespacial declarada. Los fragmentos documentan esa ausencia y los avances materiales que si constan.
q046	Pregunta por minerales estrategicos en plural. El unico mineral que el corpus documenta como fuente de financiacion es el oro; no hay material sobre coltan o casiterita.
q047	Pregunta por rutas aereas. El corpus documenta corredores maritimos, fluviales y terrestres, con un unico registro sobre pistas clandestinas de aterrizaje.

7.2 Material excluido a proposito

El observatorio Amazon_Underworld aporta 10.971 chunks al fenomeno 3, una masa considerable, y aun asi no aparece en el ground truth. Al inspeccionarlo resulta ser exclusivamente teselas vectoriales .pbf y CSV geoespaciales con codigos de division administrativa y superficies en kilometros cuadrados. No contiene prosa y no puede sustentar ninguna respuesta.

8. Como usar este ground truth

El archivo sirve para medir la capacidad de recuperacion del RAG: se lanza cada question contra el retriever y se comparan los chunk_id devueltos contra los de relevant_chunks. Con relevancia graduada por rank se pueden calcular Recall@k, MRR y nDCG@5.

Conviene tener presentes tres limites al interpretar los resultados:

- **No es exhaustivo.** Marca cinco fragmentos relevantes por pregunta, no todos los que existen. Un chunk recuperado que no este en la lista no es necesariamente un falso positivo, de modo que la precision medida sera un limite inferior.
- **Esta sesgado hacia lo lexico.** Los candidatos se generaron con BM25, asi que un fragmento pertinente que no comparta vocabulario con la pregunta ni con su expansion pudo quedar fuera del pool revisado. Un retriever dense podria encontrar aciertos legitimos no listados.
- **Hay chunks repetidos entre preguntas.** 250 referencias corresponden a 234 chunks distintos, porque varias preguntas comparten evidencia. Es correcto y esperable.

9. Reproducibilidad

La construccion esta repartida en scripts de un solo proposito, ejecutados en este orden:

Script	Funcion
build_index.py	Tokeniza el JSONL y construye el indice BM25 disperso mas los desplazamientos de linea.
buscar.py	Recuperacion BM25, filtros de ruido y lectura puntual de chunks por desplazamiento.
consultas.py	Las 50 preguntas con su expansion bilingue de terminos.
candidatos.py	Genera el pool de candidatos por pregunta y colapsa casi-duplicados.

refinar.py	Consultas dirigidas para las preguntas con pool debil.
seleccion.py	La seleccion revisada a mano: chunk_id mas ancla textual, por pregunta y orden.
generar_ground_truth.py	Extrae los excerpt, valida y escribe ground_truth.json.

La seleccion final es un juicio humano sobre candidatos recuperados automaticamente. Lo reproducible por completo es la recuperacion; el criterio de relevancia y el orden quedan explicitos en seleccion.py para poder discutirlos o corregirlos fragmento a fragmento.